Domanda 1

Richiesta: *"Quale applicazione tra quelle monitorate assorbe il maggior rate di CPU, e quanti core impiega complessivamente?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	29.24 s	86.065 + 3.013 = 89.078	Errata / Sovrastimata
L2: Agentic Recon	3.63 s	1.547 + 97 = 1.644	Esatta
L3: Deterministic	3.65 s	1.629 + 110 = 1.739	Esatta al decimillesimo

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	46.85 s	4.668 + 730 = 5.398	Parziale / Non aggregata
L2: Agentic Recon	9.05 s	1.561 + 462 = 2.023	Esatta
L3: Deterministic	9.25 s	1.643 + 367 = 2.010	Esatta al decimillesimo

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	24.11 s	4.845 + 1.085 = 5.930	Corretta (rate 5m)

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L2: Agentic Recon	13.13 s	2.694 + 943 = 3.637	Esatta + Raccomandazioni
L3: Deterministic	11.81 s	2.775 + 856 = 3.631	Esatta + Throttling/HPA

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	26.80 s	89.790 + 893 = 90.683	Corretta (rate 5m)
L2: Agentic Recon	7.53 s	2.694 + 538 = 3.232	Esatta + Analisi quote
L3: Deterministic	6.81 s	2.775 + 502 = 3.277	Esatta + Analisi disco

Domanda 2

Richiesta: *"Qual è l'uso effettivo di memoria Working Set (in MB) dell'applicazione con il maggior numero di pod o repliche?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	24.66 s	9.959 + 1.076 = 11.035	Corretta (misura dinamica live)

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L2: Agentic Recon	2.66 s	1.549 + 353 = 1.902	Esatta (aderente allo snapshot)
L3: Deterministic	3.93 s	1.631 + 374 = 2.005	Esatta (aderente allo snapshot)

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	16.07 s	3.736 + 804 = 4.540	Ottima (rileva pareggio a 2 repliche)
L2: Agentic Recon	7.49 s	1.563 + 509 = 2.072	Esatta (riporta entrambe a 2 repliche)
L3: Deterministic	10.29 s	1.645 + 497 = 2.142	Esatta al decimillesimo

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	19.76 s	6.990 + 1.061 = 8.051	Eccellente (distingue MiB vs MB)
L2: Agentic Recon	9.12 s	2.696 + 791 = 3.487	Esatta + Analisi idle e HPA
L3: Deterministic	11.04 s	2.777 + 810 = 3.587	Esatta + Avvertenza Working Set vs RSS

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza / Esito
L1: Zero-Context	17.43 s	7.063 + 1.100 = 8.163	Eccellente (esclude pod pause)
L2: Agentic Recon	15.36 s	6.518 + 1.377 = 7.895	Esatta (interroga Prometheus per verifica)
L3: Deterministic	32.35 s	6.459 + 1.235 = 7.694	Esatta (ha invocato tool per conferma)

Domanda 3

Richiesta: *"Quale applicazione genera un flusso attivo di scrittura su disco e a quale rate scrive?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza/Esito
L1: Zero-Context	28.76 s	59.613 + 1.061 = 60.674	Parziale: include servizi di sistema (etcd, grafana, prom)
L2: Agentic Recon	1.43 s	1.539 + 125 = 1.664	Esatta: risposta istantanea conforme allo snapshot
L3: Deterministic	2.16 s	1.621 + 184 = 1.805	Esatta: latenza minima, 0 tool chiamati

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza/Esito
L1: Zero-Context	27.46 s	4.969 + 575 = 5.544	Corretta identificazione: include duplicazione pod/container
L2: Agentic Recon	23.23 s	1.553 + 406 = 1.959	Esatta: conversione accurata in KiB/s
L3: Deterministic	10.03 s	1.635 + 422 = 2.057	Esatta al centesimo: conversione a 313,32 KiB/s

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Accuratezza/Esito
L1: Zero-Context	49.25 s	11.872 + 1.804 = 13.676	Critica avanzata: rileva e scorpora il doppio conteggio Prometheus
L2: Agentic Recon	13.87 s	2.683 + 1.150 = 3.833	Esatta: stima 8,8 GB/die, allarme DiskPressure ed emptyDir
L3: Deterministic	12.37 s	2.764 + 1.109 = 3.873	Esatta: stima 27,7 GB/die, suggerimenti su quote ephemeral

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L1: Zero-Context	29.87 s	89.715 + 834 = 90.549	Corretta: query rate 5m sul pod, esplosione token input
L2: Agentic Recon	4.66 s	2.683 + 458 = 3.141	Esatta: correla assenza di traffico di rete a persistenza AOF/log
L3: Deterministic	5.32 s	2.764 + 506 = 3.270	Esatta: isolamento del carico e correlazione I/O

Domanda 4

Richiesta: *"Identifica l'applicazione con il maggior numero di repliche: elenca i relativi pod e indica quante repliche risultano attive."*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L1: Zero-Context	7.18 s	2.194 + 532 = 2.726	Si arresta alla prima trovata
L2: Agentic Recon	1.63 s	1.550 + 217 = 1.767	Risposta secca conforme allo script
L3: Deterministic	1.74 s	1.632 + 195 = 1.827	Istantaneo, token minimizzati

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L1: Zero-Context	69.61 s	8.064 + 709 = 8.773	Completa, ma latenza anomala (~70s)
L2: Agentic Recon	5.84 s	1.564 + 661 = 2.225	Elenco esaustivo di tutti i pod
L3: Deterministic	8.78 s	1.646 + 438 = 2.084	Completo e analitico

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L1: Zero-Context	23.18 s	10.880 + 1.115 = 11.995	Incrocio K8s + PromQL, note su PDB/Rollout
L2: Agentic Recon	8.82 s	2.694 + 815 = 3.509	Rileva hash ReplicaSet, consiglia ridimensionamento
L3: Deterministic	7.73 s	2.775 + 645 = 3.420	Analisi SRE (HPA su worker, scale-down su demo)

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L1: Zero-Context	17.58 s	10.094 + 773 = 10.867	Completa, esclude namespace infrastrutturali
L2: Agentic Recon	5.27 s	2.694 + 632 = 3.326	Evidenzia carico asimmetrico (idle vs CPU)

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento
L3: Deterministic	4.80 s	2.775 + 538 = 3.313	Nessun tool chiamato, analisi incrociata

Domanda 5

Richiesta: *"C'è qualche applicazione che presenta traffico di rete in ricezione superiore a 10 KB/s? Se sì, quale e a quale rate?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	13.62 s	5.961 + 1.426 = 7.387	Errata: inquina con il namespace monitoring di sistema
L2: Agentic Recon	1.71 s	1.554 + 266 = 1.820	Esatta: risposta istantanea
L3: Deterministic	1.84 s	1.636 + 250 = 1.886	Esatta: 0 chiamate esterne

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	192.89 s	8.167 + 1.063 = 9.230	Latenza critica (~3.2 min), scissione utente vs infrastruttura
L2: Agentic Recon	4.26 s	1.568 + 457 = 2.025	Esatta: rientra nei parametri nominali

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L3: Deterministic	6.12 s	1.650 + 397 = 2.047	Esatta: dettaglio per singolo carico

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	39.38 s	15.924 + 1.338 = 17.262	Incrocio con storico MongoDB (2h) e analisi cAdvisor pause
L2: Agentic Recon	8.20 s	2.700 + 657 = 3.357	Esatta: diagnosi metodologica su interfaccia eth0 / container pause
L3: Deterministic	9.03 s	2.781 + 797 = 3.578	Esatta: consiglia query PromQL per pod senza filtro container

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	32.13 s	184.094 + 1.184 = 185.278	Corretta, ma esplosione record di input token (184k)
L2: Agentic Recon	5.27 s	2.700 + 483 = 3.183	Esatta: rileva anomalia I/O disco (100 KB/s) con rete a zero
L3: Deterministic	4.10 s	2.781 + 432 = 3.213	Esatta: confronta i 320 KB/s di scrittura su disco

Domanda 6

Richiesta: *"Calcola un indice di interferenza normalizzato per ogni applicazione con la formula: 50% CPU, 25% Memoria (su 128MB) e 25% scrittura su Disco (su 1 MB/s). Quale applicazione ottiene il punteggio più alto?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Matematico
L1: Zero-Context	52.09 s	8.273 + 7.167 = 15.440	Corretta, ma alta latenza ed emissione verbosa dei calcoli
L2: Agentic Recon	10.48 s	1.586 + 2.524 = 4.110	Esatta al decimillesimo: applica la formula direttamente sui dati JSON
L3: Deterministic	11.16 s	1.672 + 2.162 = 3.834	Esatta al decimillesimo: risolta in un unico turno senza tool

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Matematico
L1: Zero-Context	110.95 s	12.950 + 882 = 13.832	Fallita: bloccato nel loop ReAct oltre 110s, esauriti i 4 turni
L2: Agentic Recon	16.44 s	1.600 + 2.333 = 3.933	Esatta: passaggi matematici espliciti, nessun tool esterno chiamato
L3: Deterministic	20.79 s	1.686 + 2.153 = 3.839	Esatta: resa percentuale (19.51%) e formula dettagliata

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Matematico
L1: Zero-Context	32.66 s	8.140 + 2.341 = 10.481	Analisi SRE avanzata: a livello di singolo pod rileva che vince cache-app (0.234)
L2: Agentic Recon	17.87 s	2.742 + 1.664 = 4.406	Esatta: rileva che il 97% del punteggio deriva dal carico CPU
L3: Deterministic	17.02 s	2.825 + 1.500 = 4.325	Esatta: 0 chiamate esterne, raccomandazioni su anti-affinity e HPA

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Matematico
L1: Zero-Context	33.70 s	91.090 + 2.415 = 93.505	Corretta, ma esplosione a 91.090 input token per dump Prometheus
L2: Agentic Recon	11.73 s	2.742 + 1.459 = 4.201	Esatta: confronta normalizzazione con MB decimali vs MiB binari
L3: Deterministic	13.52 s	2.825 + 1.425 = 4.250	Esatta: verifica robustezza classifica (aggregato vs per pod)

Domanda 7

Richiesta: *"Seleziona l'applicazione che consuma più memoria e calcola la variazione percentuale della sua memoria nelle ultime 2 ore interrogando lo storico."*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Storico
L1: Zero-Context	19.41 s	8.358 + 2.285 = 10.643	Esatta: calcolo eseguito sui byte grezzi
L2: Agentic Recon	12.05 s	4.881 + 849 = 5.730	Esatta: invoca autonomamente il tool MongoDB
L3: Deterministic	43.03 s	3.654 + 1.093 = 4.747	Esatta: invoca tool MongoDB ed elabora delta su MB

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Storico
L1: Zero-Context	26.61 s	7.914 + 1.284 = 9.198	Esatta: formula LaTeX esplicita e passaggi completi
L2: Agentic Recon	18.54 s	4.672 + 1.134 = 5.806	Esatta: verifica timestamps temporali e calcolo preciso
L3: Deterministic	48.28 s	3.595 + 1.217 = 4.812	Esatta: fornisce sia il calcolo su MB sia quello sui byte grezzi

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Storico
L1: Zero-Context	28.20 s	9.098 + 1.685 = 10.783	Superiore: analizza 13 campioni su MongoDB, esclude memory leak

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Storico
L2: Agentic Recon	21.25 s	7.441 + 1.190 = 8.631	Critica analitica: scarta un campione anomalo a 0 B alle 07:18:10
L3: Deterministic	51.34 s	6.045 + 1.292 = 7.337	Diagnosi avanzata: evidenzia che ci sono solo 3 campioni (17 min)

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Storico
L1: Zero-Context	27.16 s	135.599 + 1.686 = 137.285	Esatta, ma esplosione input token (135k) per dump Prometheus
L2: Agentic Recon	17.30 s	7.496 + 993 = 8.489	Superiore: avverte che i campioni coprono 72 min e non 2h piene
L3: Deterministic	43.96 s	6.051 + 1.031 = 7.082	Superiore: nota stabilità dopo calo iniziale, consiglia prom_range

Domanda 8

Richiesta: *"Assumendo che l'applicazione a maggior carico di CPU abbia un limit di 300m per pod (600m totali su 2 repliche), calcola la percentuale di saturazione e valuta il rischio di throttling."*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Valutazione Rischio & Comportamento SRE
L1: Zero-Context	27.45 s	4.859 + 3.939 = 8.798	Moderato-alto (consiglia aumento limit a 400-500m)
L2: Agentic Recon	3.52 s	1.572 + 603 = 2.175	Alto rischio: risposta secca immediata (0 tool)
L3: Deterministic	6.67 s	1.658 + 1.350 = 3.008	Basso: margine 38.58%, 0 tool invocati

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Valutazione Rischio & Comportamento SRE
L1: Zero-Context	38.11 s	11.562 + 2.422 = 13.984	Molto Alto / Critico: rileva cfs_throttled tra 77.7% e 82.0%
L2: Agentic Recon	23.41 s	1.586 + 1.426 = 3.012	Critico / Molto Elevato: dettaglio quote CFS, aumento limit
L3: Deterministic	10.03 s	1.672 + 1.278 = 2.950	Basso-Moderato: avverte su micro-burst CFS 100ms

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Valutazione Rischio & Comportamento SRE
L1: Zero-Context	40.38 s	9.129 + 2.063 = 11.192	Critico: cfs_throttled a 76.8%-83%, picchi a 1 min al 99%

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Valutazione Rischio & Comportamento SRE
L2: Agentic Recon	28.94 s	6.114 + 1.932 = 8.046	Critico (in corso): interroga Prometheus, throttled >92%
L3: Deterministic	22.83 s	2.806 + 2.048 = 4.854	Medio-Basso: 0 tool calls, query PromQL e HPA target 70%

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Valutazione Rischio & Comportamento SRE
L1: Zero-Context	50.26 s	138.797 + 2.715 = 141.512	Alto / Critico: picchi 98-99%, throttled 77-83%, storico 6h
L2: Agentic Recon	25.23 s	8.294 + 2.171 = 10.465	Critico (in corso): interroga Prometheus, throttled 93-95%
L3: Deterministic	12.07 s	2.806 + 1.462 = 4.268	Basso-Moderato: 0 tool, calcola soglia sbilanciamento >81%

Domanda 9

Richiesta: *"Interroga Prometheus per verificare se ci sono stati riavvii imprevisti di container nel namespace default nell'ultima ora."*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Diagnostico
L1: Zero-Context	8.31 s	1.023 + 0 = 1.023	Fallita: 0 token di completamento emessi (risposta vuota)
L2: Agentic Recon	17.03 s	8.266 + 1.196 = 9.462	Auto-dichiarazione del limite: fallisce su prom_range e consiglia un modello superiore
L3: Deterministic	35.98 s	4.057 + 907 = 4.964	Esatta: esegue tool-calling senza andare in loop o fallire

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Diagnostico
L1: Zero-Context	74.18 s	57.169 + 1.235 = 58.404	Corretta (tabella 5 container, contatore storico a 40)
L2: Agentic Recon	13.27 s	3.906 + 505 = 4.411	Esatta: verifica tutti i 5 carichi applicativi
L3: Deterministic	56.02 s	7.385 + 687 = 8.072	Esatta: analizza i 5 pod ed evidenzia lo storico a 44

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Diagnostico
L1: Zero-Context	46.51 s	18.149 + 2.018 = 20.167	Superiore: analizza il contatore a 40 e deduce il riavvio del nodo/cluster
L2: Agentic Recon	34.30 s	20.657 + 1.918 = 22.575	Superiore: nota incremento a 44 riavvii e isola cambi IP di kube-state-metrics
L3: Deterministic	90.39 s	51.948 + 3.881 = 55.829	Diagnosi critica approfondita: rileva campioni mancanti, scrape 30s e reboot cluster

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento Diagnostico
L1: Zero-Context	55.52 s	35.650 + 3.326 = 38.976	Diagnosi avanzata: individua incoerenza tra increase() e salto 39 → 40
L2: Agentic Recon	16.52 s	7.722 + 1.037 = 8.759	Superiore: segnala presenza pregressa di last_terminated_reason='Unknown'
L3: Deterministic	41.76 s	7.810 + 874 = 8.684	Superiore: conferma 0 nell'ultima ora, storicizza i 44 restart precedenti

Domanda 10

Richiesta: *"Dobbiamo sottomettere un nuovo batch da 12 pod con vincolo critico di CPU. In base alle risorse attuali, accanto a quale applicazione è più sicuro collocarli e da quale devono essere isolati?"*

Gemini 2.5 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	30.59 s	3.746 + 807 = 4.553	Corretta: individua contesa potenziale su worker
L2: Agentic Recon	2.81 s	1.568 + 454 = 2.022	Esatta e immediata: 0 chiamate MCP
L3: Deterministic	2.29 s	1.654 + 361 = 2.015	Esatta e istantanea: 0 tool chiamati

Gemini 3.8 Flash

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	47.45 s	15.040 + 458 = 15.498	Fallita: esauriti i 4 turni ReAct senza testo finale
L2: Agentic Recon	10.56 s	1.582 + 1.322 = 2.904	Esatta: fornisce manifest YAML con podAntiAffinity verso worker-app e QoS Guaranteed
L3: Deterministic	11.69 s	1.668 + 1.231 = 2.899	Esatta: manifest YAML completo podAntiAffinity e classe Guaranteed

Claude Opus 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	87.48 s	37.716 + 3.036 = 40.752	Analisi SRE avanzata: scopre cluster mono-nodo, anti-affinity inefficace senza 2° nodo, QoS Guaranteed e CPU Manager static
L2: Agentic Recon	20.40 s	2.729 + 1.917 = 4.646	Superiore: YAML con affinità pesata; evidenzia che lo snapshot non riporta la mappatura nodi-pod
L3: Deterministic	41.66 s	12.436 + 2.654 = 15.090	Indagine topologica attiva: interroga Prometheus per verificare l'infrastruttura nodale (8 core allocabili)

Claude Sonnet 5.5

Livello Architetturale	Latenza Query	Token Totali (Input + Output = Totale)	Note di Accuratezza e Comportamento SRE
L1: Zero-Context	66.46 s	196.237 + 2.662 = 198.899	Record storico token di input (196k): rileva cluster mono-nodo da 8 core allocabili (~6.6 liberi)
L2: Agentic Recon	11.06 s	2.729 + 1.259 = 3.988	Superiore: esclude cache-app per I/O disco; fornisce regole YAML e suggerisce verifica allocabile
L3: Deterministic	12.25 s	2.812 + 1.330 = 4.142	Superiore: 0 chiamate esterne, evidenzia la carenza di dati sui nodi e modella QoS e affinity

Latenza Gemini 2.5 Flash

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	29.24 s	3.63 s	3.65 s
Domanda 2	24.66 s	2.66 s	3.93 s
Domanda 3	28.76 s	1.43 s	2.16 s
Domanda 4	7.18 s	1.63 s	1.74 s
Domanda 5	13.62 s	1.71 s	1.84 s
Domanda 6	52.09 s	10.48 s	11.16 s
Domanda 7	19.41 s	12.05 s	43.03 s
Domanda 8	27.45 s	3.52 s	6.67 s
Domanda 9	8.31 s	17.03 s	35.98 s
Domanda 10	30.59 s	2.81 s	2.29 s

Latenza Gemini 3.8 Flash

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	46.85 s	9.05 s	9.25 s
Domanda 2	16.07 s	7.49 s	10.29 s
Domanda 3	27.46 s	23.23 s	10.03 s

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 4	69.61 s	5.84 s	8.78 s
Domanda 5	192.89 s	4.26 s	6.12 s
Domanda 6	110.95 s	16.44 s	20.79 s
Domanda 7	26.61 s	18.54 s	48.28 s
Domanda 8	38.11 s	23.41 s	10.03 s
Domanda 9	74.18 s	13.27 s	56.02 s
Domanda 10	47.45 s	10.56 s	11.69 s

Latenza Claude Opus 5.5

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	24.11 s	13.13 s	11.81 s
Domanda 2	19.76 s	9.12 s	11.04 s
Domanda 3	49.25 s	13.87 s	12.37 s
Domanda 4	23.18 s	8.82 s	7.73 s
Domanda 5	39.38 s	8.20 s	9.03 s
Domanda 6	32.66 s	17.87 s	17.02 s
Domanda 7	28.20 s	21.25 s	51.34 s
Domanda 8	40.38 s	28.94 s	22.83 s

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 9	46.51 s	34.30 s	90.39 s
Domanda 10	87.48 s	20.40 s	41.66 s

Latenza Claude Sonnet 5.5

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	26.80 s	7.53 s	6.81 s
Domanda 2	17.43 s	15.36 s	32.35 s
Domanda 3	29.87 s	4.66 s	5.32 s
Domanda 4	17.58 s	5.27 s	4.80 s
Domanda 5	32.13 s	5.27 s	4.10 s
Domanda 6	33.70 s	11.73 s	13.52 s
Domanda 7	27.16 s	17.30 s	43.96 s
Domanda 8	50.26 s	25.23 s	12.07 s
Domanda 9	55.52 s	16.52 s	41.76 s
Domanda 10	66.46 s	11.06 s	12.25 s

Token Gemini 2.5 Flash

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	86.065 + 3.013 = 89.078	1.547 + 97 = 1.644	1.629 + 110 = 1.739

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 2	9.959 + 1.076 = 11.035	1.549 + 353 = 1.902	1.631 + 374 = 2.005
Domanda 3	59.613 + 1.061 = 60.674	1.539 + 125 = 1.664	1.621 + 184 = 1.805
Domanda 4	2.194 + 532 = 2.726	1.550 + 217 = 1.767	1.632 + 195 = 1.827
Domanda 5	5.961 + 1.426 = 7.387	1.554 + 266 = 1.820	1.636 + 250 = 1.886
Domanda 6	8.273 + 7.167 = 15.440	1.586 + 2.524 = 4.110	1.672 + 2.162 = 3.834
Domanda 7	8.358 + 2.285 = 10.643	4.881 + 849 = 5.730	3.654 + 1.093 = 4.747
Domanda 8	4.859 + 3.939 = 8.798	1.572 + 603 = 2.175	1.658 + 1.350 = 3.008
Domanda 9	1.023 + 0 = 1.023	8.266 + 1.196 = 9.462	4.057 + 907 = 4.964
Domanda 10	3.746 + 807 = 4.553	1.568 + 454 = 2.022	1.654 + 361 = 2.015

Token Gemini 3.8 Flash

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	4.668 + 730 = 5.398	1.561 + 462 = 2.023	1.643 + 367 = 2.010
Domanda 2	3.736 + 804 = 4.540	1.563 + 509 = 2.072	1.645 + 497 = 2.142
Domanda 3	4.969 + 575 = 5.544	1.553 + 406 = 1.959	1.635 + 422 = 2.057

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 4	8.064 + 709 = 8.773	1.564 + 661 = 2.225	1.646 + 438 = 2.084
Domanda 5	8.167 + 1.063 = 9.230	1.568 + 457 = 2.025	1.650 + 397 = 2.047
Domanda 6	12.950 + 882 = 13.832	1.600 + 2.333 = 3.933	1.686 + 2.153 = 3.839
Domanda 7	7.914 + 1.284 = 9.198	4.672 + 1.134 = 5.806	3.595 + 1.217 = 4.812
Domanda 8	11.562 + 2.422 = 13.984	1.586 + 1.426 = 3.012	1.672 + 1.278 = 2.950
Domanda 9	57.169 + 1.235 = 58.404	3.906 + 505 = 4.411	7.385 + 687 = 8.072
Domanda 10	15.040 + 458 = 15.498	1.582 + 1.322 = 2.904	1.668 + 1.231 = 2.899

Token Claude Opus 5.5

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	4.845 + 1.085 = 5.930	2.694 + 943 = 3.637	2.775 + 856 = 3.631
Domanda 2	6.990 + 1.061 = 8.051	2.696 + 791 = 3.487	2.777 + 810 = 3.587
Domanda 3	11.872 + 1.804 = 13.676	2.683 + 1.150 = 3.833	2.764 + 1.109 = 3.873
Domanda 4	10.880 + 1.115 = 11.995	2.694 + 815 = 3.509	2.775 + 645 = 3.420

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 5	15.924 + 1.338 = 17.262	2.700 + 657 = 3.357	2.781 + 797 = 3.578
Domanda 6	8.140 + 2.341 = 10.481	2.742 + 1.664 = 4.406	2.825 + 1.500 = 4.325
Domanda 7	9.098 + 1.685 = 10.783	7.441 + 1.190 = 8.631	6.045 + 1.292 = 7.337
Domanda 8	9.129 + 2.063 = 11.192	6.114 + 1.932 = 8.046	2.806 + 2.048 = 4.854
Domanda 9	18.149 + 2.018 = 20.167	20.657 + 1.918 = 22.575	51.948 + 3.881 = 55.829
Domanda 10	37.716 + 3.036 = 40.752	2.729 + 1.917 = 4.646	12.436 + 2.654 = 15.090

Token Claude Sonnet 5.5

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 1	89.790 + 893 = 90.683	2.694 + 538 = 3.232	2.775 + 502 = 3.277
Domanda 2	7.063 + 1.100 = 8.163	6.518 + 1.377 = 7.895	6.459 + 1.235 = 7.694
Domanda 3	89.715 + 834 = 90.549	2.683 + 458 = 3.141	2.764 + 506 = 3.270
Domanda 4	10.094 + 773 = 10.867	2.694 + 632 = 3.326	2.775 + 538 = 3.313
Domanda 5	184.094 + 1.184 = 185.278	2.700 + 483 = 3.183	2.781 + 432 = 3.213

Domanda	L1: Zero-Context	L2: Agentic Recon	L3: Deterministic
Domanda 6	91.090 + 2.415 = 93.505	2.742 + 1.459 = 4.201	2.825 + 1.425 = 4.250
Domanda 7	135.599 + 1.686 = 137.285	7.496 + 993 = 8.489	6.051 + 1.031 = 7.082
Domanda 8	138.797 + 2.715 = 141.512	8.294 + 2.171 = 10.465	2.806 + 1.462 = 4.268
Domanda 9	35.650 + 3.326 = 38.976	7.722 + 1.037 = 8.759	7.810 + 874 = 8.684
Domanda 10	196.237 + 2.662 = 198.899	2.729 + 1.259 = 3.988	2.812 + 1.330 = 4.142